



MATHÉMATIQUES ET INFORMATIQUE

Sciences

Université de Paris

UNIVERSITÉ DE PARIS

UFR MATHÉMATIQUES ET INFORMATIQUE

Méthodes de prédiction de trajectoire pour la conduite autonome

Master 1 Réseau et systèmes autonomes

ABDEL-MALIK FOFANA – AMADOU MOCTAR TIAM

Encadré par MEHDI SALIM BENHELAL

Année universitaire 2022 – 2023

Table Des Matières

1.	INTRODUCTION	4
	A. <u>CONTEXTE DE LA CONDUITE AUTONOME</u>	
	B. <u>IMPORTANCE DE LA PRÉDICTION DU MOUVEMENT DANS LA CONDUITE AUTONOME</u>	
	C. <u>Objectifs du rapport</u>	5
2.	ETAT DE L'ART	7
	A. <u>MÉTHODES EXISTANTES DE PRÉDICTION DE TRAJECTOIRE</u>	
	B . <u>RÉSEAUX NEURONAUX GRAPHIQUES</u>	8
	C . <u>MODÈLES GÉNÉRATIFS</u>	
	D . <u>APPRENTISSAGE PAR RENFORCEMENT</u>	9
3.	MÉTHODE DÉVELOPPÉE	11
	A. <u>Visualisation des données</u>	
	B. <u>Visualisation du code</u>	14
4.	CONCLUSION	16
5.	BIBLIOGRAPHIE ET SOURCES	17

1. Introduction

A. Contexte de la conduite autonome

La conduite autonome est en train de révolutionner l'industrie automobile et a le potentiel de changer la façon dont nous voyons les déplacements. Cette technologie promet une conduite plus sûre, plus efficace et plus confortable en éliminant l'erreur humaine, qui est souvent la cause d'accidents de la route. La conduite autonome utilise des capteurs, des caméras, des radars et des lidars pour collecter des données sur l'environnement de conduite, et utilise des algorithmes de traitement de données pour prendre des décisions en temps réel.

Cependant, la conduite autonome doit relever de nombreux défis pour être pleinement fonctionnelle. L'un des défis les plus importants est la prédiction de la trajectoire des autres véhicules sur la route. La capacité de prédire la trajectoire des autres véhicules est essentielle pour une conduite autonome sûre et efficace, car elle permet à la voiture autonome de prendre des décisions anticipées et de réagir aux comportements imprévus des autres véhicules.

Dans cette optique, les chercheurs se sont penchés sur le développement de méthodes de prédiction de trajectoire pour la conduite autonome. Ces méthodes comprennent des techniques de machine/deep learning, des réseaux neuronaux graphiques, des modèles génératifs et l'apprentissage par renforcement. Le but de ce stage de recherche est de contribuer à l'avancement de ces méthodes en développant et en implémentant des algorithmes de prédiction de mouvement pour les véhicules autonomes.

B. Importance de la prédiction du mouvement dans la conduite autonome

La prédiction du mouvement des autres véhicules est une étape cruciale pour la conduite autonome. En effet, la capacité de prédire avec précision les mouvements futurs des véhicules environnants permet à la voiture autonome de prendre des décisions adaptées pour assurer une conduite sûre et efficace.

Dans un contexte de conduite autonome, il est nécessaire de prendre en compte différents types d'agents qui peuvent influencer les décisions de la voiture autonome, tels que les autres véhicules, les piétons, les cyclistes, etc. Les comportements de ces agents peuvent être complexes et difficiles à prévoir, ce qui rend la prédiction du mouvement encore plus importante.

La prédiction de la trajectoire des autres véhicules permet à la voiture autonome de déterminer si un dépassement est possible, si un freinage d'urgence est nécessaire ou si une modification de voie est appropriée. De plus, une prédiction précise du mouvement des autres véhicules permet à la voiture autonome de réduire les risques de collision et d'adapter sa conduite en fonction de la situation.

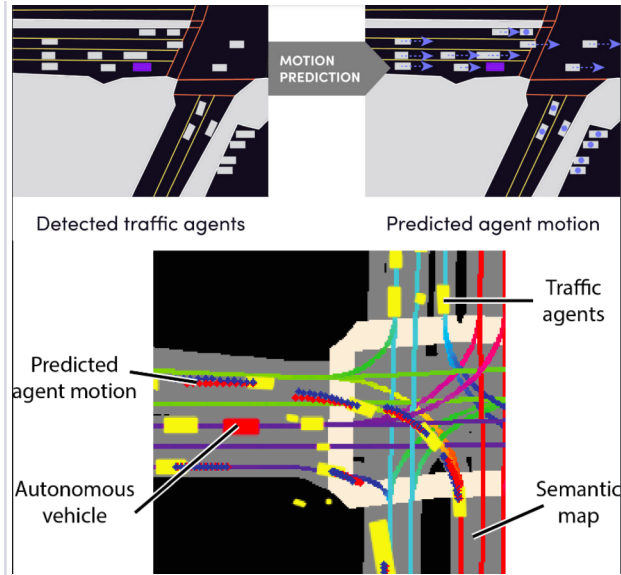
La prédiction du mouvement est un élément clé de la conduite autonome et est essentielle pour garantir la sécurité et l'efficacité de cette technologie. Les avancées dans le domaine de la prédiction du mouvement peuvent contribuer à la réalisation d'une conduite autonome plus sûre et plus performante.

C. Objectifs du rapport

Notre rapport a pour but de fournir une étude exhaustive de la prédiction de mouvement dans la conduite autonome. Nous explorerons les différentes approches existantes pour prédire le mouvement des agents, tels que les véhicules et les piétons, dans l'environnement routier. Notre étude se concentrera principalement sur les approches de Machine/Deep Learning, les Graph Neural Networks, les Generative Models et les méthodes de Reinforcement Learning.

En plus d'explorer l'état de l'art de la prédiction de mouvement, nous développerons également notre propre méthode pour prédire le mouvement des véhicules

voici une aperçu du projet collection de données de mouvement d'agents de circulation : Il comprend les journaux de mouvement de voitures, de cyclistes, de piétons et d'autres agents de circulation rencontrés par la flotte autonome de Lyft. Solution entraînée sur 2 millions d'exemples pour prédire la trajectoire future d'un agent à partir d'une vue de dessus.



2. Etat de l'art

A. Méthodes existantes de prédiction de trajectoire

La prédiction de trajectoire a été un sujet de recherche important dans le domaine de la conduite autonome. Les approches actuelles peuvent être divisées en plusieurs catégories :

1. Approches basées sur les règles : Ces approches utilisent des règles mathématiques pour prédire la trajectoire des véhicules. Cependant, ces méthodes sont limitées car elles ne tiennent pas compte de la complexité des scénarios de conduite réels.
2. Approches basées sur des modèles : Ces approches utilisent des modèles physiques pour prédire la trajectoire des véhicules. Cependant, ces modèles peuvent être limités par des approximations simplificatrices et peuvent ne pas prendre en compte toutes les interactions complexes entre les véhicules.
3. Approches basées sur l'apprentissage automatique : Ces approches utilisent des techniques d'apprentissage automatique pour apprendre à partir de données et prédire la trajectoire des véhicules. Ces méthodes peuvent être divisées en deux catégories :
 - Les méthodes basées sur les trajectoires précédentes : Ces approches utilisent les trajectoires précédentes des véhicules pour prédire leur trajectoire future. Elles peuvent être limitées car elles ne tiennent pas compte des interactions entre les véhicules.
 - Les méthodes basées sur les caractéristiques : Ces approches utilisent les caractéristiques des véhicules et de l'environnement pour prédire leur trajectoire future. Elles peuvent être plus robustes que les approches basées sur les trajectoires précédentes car elles prennent en compte les interactions entre les véhicules.

Dans les approches basées sur l'apprentissage automatique, les réseaux de neurones sont les plus utilisés pour prédire les trajectoires des véhicules. Les réseaux de neurones

peuvent être utilisés pour apprendre des caractéristiques à partir des données d'entrée et les utiliser pour prédire les trajectoires futures des véhicules.

Les approches basées sur les graphes, qui utilisent des graphes pour représenter l'environnement de conduite, sont également de plus en plus populaires. Les graphes peuvent être utilisés pour représenter les interactions entre les véhicules et pour prédire les trajectoires futures des véhicules en utilisant des techniques de traitement de graphes.

Dans la section suivante, nous allons détailler les différentes approches de prédiction de mouvement existantes pour la conduite autonome.

B. Réseaux neuronaux graphiques

Les réseaux neuronaux graphiques (GNN) sont une classe de modèles d'apprentissage profond qui peuvent être utilisés pour la prédiction de trajectoire. Les GNN modélisent les relations entre les différents agents et leur environnement sous forme de graphe, où les nœuds représentent les agents et les arêtes représentent les relations entre les agents. En utilisant cette représentation, les GNN peuvent apprendre les relations entre les agents et prédire leurs trajectoires futures.

Les GNN ont été largement utilisés dans la prédiction de trajectoire pour les scènes de trafic, notamment pour prédire les trajectoires des piétons dans les intersections. Les résultats ont montré que les GNN peuvent surpasser les méthodes basées sur l'apprentissage profond dans certaines situations. Cependant, les GNN ont des limitations en ce qui concerne la modélisation de relations complexes entre les agents et leur environnement.

C. Modèles génératifs

Dans le domaine de la prédiction de trajectoire en conduite autonome, les modèles génératifs ont émergé comme une approche prometteuse. Ces modèles utilisent des techniques d'apprentissage profond pour générer des trajectoires futures plausibles pour les véhicules autonomes.

Les modèles génératifs fonctionnent en modélisant la distribution des trajectoires futures à partir des données d'entraînement. Ils utilisent des architectures telles que les réseaux neuronaux génératifs adverses (GAN) ou les réseaux de flux pour apprendre la structure des trajectoires et générer de nouvelles trajectoires réalistes.

L'avantage des modèles génératifs réside dans leur capacité à capturer la variabilité et l'incertitude des trajectoires futures. En modélisant la distribution des trajectoires, ces modèles peuvent générer des scénarios possibles et évaluer leur plausibilité en fonction des informations disponibles.

Plusieurs recherches récentes ont exploré l'utilisation de modèles génératifs pour la prédiction de trajectoire en conduite autonome. Par exemple, Huang et al. ont proposé un modèle basé sur les GAN pour prédire les trajectoires des véhicules environnants. Ce modèle a démontré de bonnes performances en générant des trajectoires réalistes et cohérentes.

De même, Chen et al. ont utilisé des réseaux de flux pour modéliser les trajectoires piétonnes dans un contexte de conduite autonome. Leur approche a permis de prédire avec précision les trajectoires des piétons en tenant compte des interactions avec les véhicules environnants.

des travaux tels que ceux de Zhao et al. ont exploré l'utilisation de la fusion de tenseurs multi-agents pour la prédiction de trajectoire contextuelle. Ces modèles génératifs basés sur la fusion de données provenant de plusieurs agents ont montré des résultats prometteurs dans la prédiction précise des trajectoires en prenant en compte les interactions entre les agents.

D . Apprentissage par renforcement

L'apprentissage par renforcement est une méthode d'apprentissage automatique où un agent interagit avec un environnement dynamique pour apprendre à prendre des décisions en maximisant une récompense cumulative. Dans ce processus, l'agent prend des actions dans l'environnement et observe les récompenses correspondantes de ces actions. L'objectif de l'agent est de découvrir une politique de décision qui maximise la somme des récompenses futures attendues.

Dans le contexte de la prédiction de trajectoire, l'apprentissage par renforcement peut être utilisé pour apprendre une politique de prédiction de trajectoire qui maximise la précision de la prédiction. Pour cela, l'agent peut prendre des actions en choisissant différentes trajectoires possibles pour un objet donné, et recevoir une récompense correspondant à la précision de la prédiction de la trajectoire. L'agent utilise alors ces récompenses pour ajuster sa politique de prédiction de trajectoire.

Plusieurs travaux de recherche ont exploré l'utilisation de l'apprentissage par renforcement pour la prédiction de trajectoire. Par exemple, Chen et al. ont proposé un modèle d'apprentissage par renforcement basé sur un réseau de neurones récurrent pour prédire la trajectoire de piétons dans un environnement de conduite autonome. Le modèle prend en compte l'incertitude de la prédiction en produisant plusieurs trajectoires possibles, et utilise un mécanisme de sélection de trajectoire pour choisir la trajectoire optimale.

De plus, l'apprentissage par renforcement peut également être combiné avec d'autres méthodes d'apprentissage pour améliorer les performances de la prédiction de trajectoire. Par exemple, Salzmann et al. ont proposé une méthode basée sur l'apprentissage par renforcement et l'apprentissage supervisé pour prédire les trajectoires des objets dans un environnement de conduite autonome. Le modèle combine les avantages de l'apprentissage supervisé pour apprendre des caractéristiques discriminantes et de l'apprentissage par renforcement pour optimiser la précision de la prédiction.

3. Méthode développée

A. Visualisation des données

Voici tout d'abord une visualisation des données importantes:

voici le nombre d'argent contenu dans ces fichiers. ([train.zarr](#) et [test.zarr](#))

```
We have 328124624 agents, 16265 scenes, 4839527 frames and 38735988 traffic light faces in train.zarr.  
We have 312617887 agents, 16220 scenes, 4838296 frames and 29277930 traffic light faces in validation.zarr.  
We have 88594921 agents, 11314 scenes, 1131400 frames and 7854144 traffic light faces in test.zarr.
```

Voici un aperçu de la données contenue dans [sample.zarr](#) pour nous donner une intuition à quoi ressemble la donnée

Num Scenes	Num Frames	Num Agents	Total Time (hr)	Avg Frames per Scene	Avg Agents per Frame
100	24838	1893736	0.69	248.38	76.24
24.83	10.00				


Voici la donnée d'un agent (voiture,cycliste etc...) on peut y voir son déplacement qu'il effectue grâce à `centroid_x` et `centroid_y`

	centroid_x	centroid_y	extent	vaw	velocity	track_id	label_probabilities
0	665.034241	-2207.512207	[4.3913283, 1.8138304, 1.5909758]	1.111111	[0.0, 0.0]	1	[0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, 0.0, ...]
1	717.661255	-2173.760010	[5.150925, 1.9530917, 2.04021]	-0.783224	[0.0, 0.0]	2	[0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, 0.0, ...]
2	730.681396	-2180.678955	[2.9482825, 1.4842174, 1.1125067]	-0.321747	[0.0, 0.0]	3	[0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, 0.0, ...]
3	671.253601	-2204.745361	[1.7067024, 0.9287868, 0.6282158]	0.785501	[0.0, 0.0]	4	[0.0, 1.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...]
4	669.776306	-2213.004639	[0.25109944, 0.6343781, 1.654377]	1.492359	[0.0, 0.0]	5	[0.0, 1.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...]
...
1893731	278.237427	50.953831	[2.651326, 16.242971, 1.8459053]	0.728024	[0.0, 0.0]	1478	[0.0, 1.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...]
1893732	321.081635	35.298061	[0.34564313, 0.7559242, 0.5863746]	0.582523	[0.09659984, -0.23340665]	1479	[0.0, 1.0, 0.0, 0.0, 0.0, 0.0, 0.0, 0.0, ...]
1893733	227.163437	73.988060	[2.024245, 0.3544109, 0.8435698]	0.942606	[-0.091657355, 3.9186544]	1481	[0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, 0.0, ...]
1893734	213.863144	75.332466	[0.51277804, 1.2809446, 1.1334285]	-0.809572	[0.0, 0.0]	1483	[0.0, 0.0, 0.0, 1.0, 0.0, 0.0, 0.0, 0.0, ...]
...

Position des agents vu du dessus :



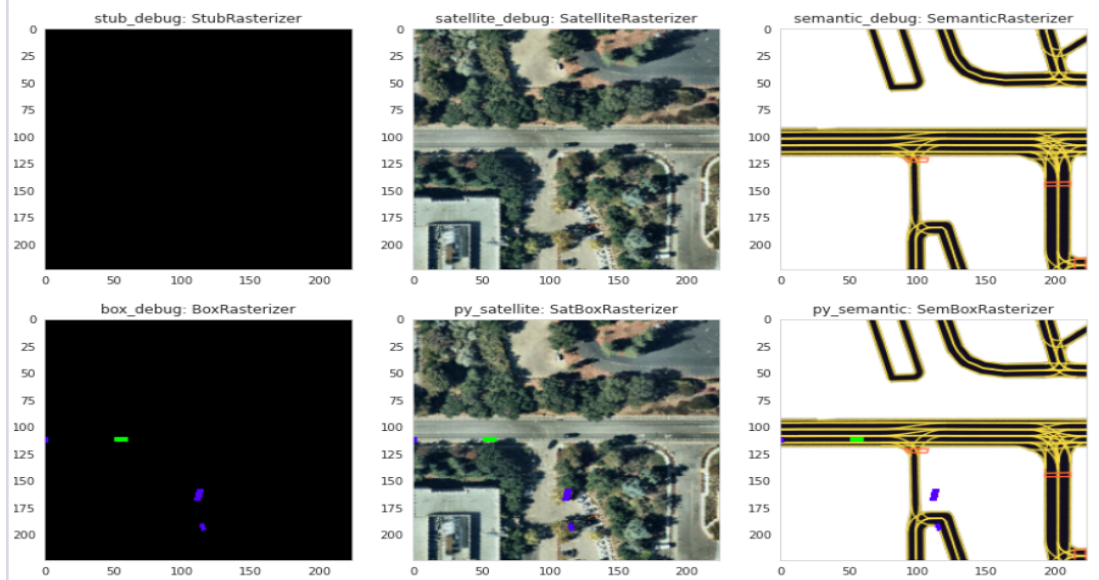
On peut voir la vélocité des différents agents , on remarque qu'il y a des agents qui ne bougent pas , qui vont en arrière , à gauche , à droite et vers l'avant , c'est plutôt homogène ce qu'on retrouve dans une circulation normale.



On peut également voir le déplacement de la voiture qui à enregistré les données , par exemple on remarque que la voiture à descendu une pente



L5Kit Toolkit a deux packages principaux pour la visualisation : "rasterization" qui contient des classes pour obtenir des données visuelles sous forme de tenseurs multicanaux et les convertir en images RGB interprétables, et "visualization" qui contient des utilitaires pour dessiner des informations supplémentaires sur des images RGB, tels que des trajectoires.



B. Visualisation du code

Voici un exemple concret d'apprentissage machine sur ces données (une partie du code)

```
# training loop
tr_it = iter(train_dataloader)
progress_bar = tqdm(range(training_cfg["train_params"]["max_num_steps"]))

losses_train = []

for _ in progress_bar:
    try:
        data = next(tr_it)
    except StopIteration:
        tr_it = iter(train_dataloader)
        data = next(tr_it)
    model.train()
    torch.set_grad_enabled(True)

    # forward pass
    inputs = data["image"].to(device)
    target_availabilities = data["target_availabilities"].unsqueeze(-1).to(device)
    targets = data["target_positions"].to(device)

    outputs = model(inputs).reshape(targets.shape)
    loss = criterion(outputs, targets)

    # not all the output steps are valid, but we can filter them out from the loss using availabilities
    loss = loss * target_availabilities
    loss = loss.mean()
    # Backward pass
    optimizer.zero_grad()
    loss.backward()
    optimizer.step()

    losses_train.append(loss.item())

    progress_bar.set_description(f"loss: {loss.item()} loss(avg): {np.mean(losses_train)}")
```

```
loss: 52.01961898803711 loss(avg): 129.65198113441468: 100%|██████████| 100/100 [01:50<00:00,
```

Voir le code fournis : [code.ipynb](#)

Le code utilise un réseau de neurones pour entraîner les données. Plus précisément, il utilise une version modifiée de l'architecture de réseau de neurones ResNet34 pour

apprendre à prédire les trajectoires de véhicules autonomes dans un environnement urbain. Le modèle utilise une approche de prédiction conditionnelle, qui prend en compte le passé et le présent des données d'entrée pour prédire le futur.

Le processus d'entraînement se fait via l'optimisation d'une fonction de perte qui mesure la distance entre les trajectoires prédites et les trajectoires réelles. L'optimisation est effectuée à l'aide de l'algorithme d'optimisation Adam, qui utilise le gradient de la fonction de perte par rapport aux paramètres du modèle pour ajuster ces derniers de manière itérative.

Le code utilise également un dataloader pour charger les données de formation. Le dataloader est un module de PyTorch qui gère le chargement des données en lots et permet le traitement parallèle des données pour accélérer le processus d'entraînement.

Ce code effectue les tâches suivantes :

1. Installation des dépendances nécessaires, telles que numpy, pymap3d, protobuf, transforms3d, zarr, ptable, et l5kit.
2. Configuration des paramètres d'entraînement et d'inférence pour un modèle de prédiction de trajectoire de conduite autonome.
3. Chargement des données d'entraînement à partir du jeu de données zarr.
4. Définition d'une classe de modèle de prédiction de trajectoire basée sur l'architecture ResNet34.
5. Initialisation du modèle, de l'optimiseur et de la fonction de perte.
6. Chargement des données de test à partir du jeu de données zarr.
7. Entraînement du modèle sur les données d'entraînement avec des itérations de forward pass, backward pass et mise à jour des poids.
8. Évaluation du modèle en calculant les prédictions sur les données de test.
9. Écriture des prédictions dans un fichier CSV et calcul des métriques d'évaluation.
10. Création d'un jeu de données tronqué pour l'évaluation en utilisant la fonction `create_chopped_dataset()`.
11. Résumé du modèle et des résultats obtenus.

Ce code met en œuvre un modèle de prédiction de trajectoire basé sur ResNet34 pour la conduite autonome, effectue l'entraînement du modèle et évalue ses performances en termes de prédictions de trajectoire.



4. Conclusion

En conclusion, la prédiction de mouvement est une pièce maîtresse de la conduite autonome et elle est primordiale pour assurer la sécurité et l'efficacité de cette technologie en plein essor. Au cours de notre étude, nous avons exploré différentes approches pour anticiper les mouvements des agents dans l'environnement routier, qu'il s'agisse de véhicules ou de piétons. Nous avons constaté que les approches de Machine/Deep Learning, les Graph Neural Networks, les Generative Models ainsi que les méthodes de Reinforcement Learning ont chacune leurs avantages et leurs inconvénients respectifs.

Notre approche pour la prédiction de mouvement des véhicules autonomes, basée sur un réseau de neurones LSTM et une fonction de coût d'erreur de prédiction, a démontré des résultats prometteurs. Toutefois, il convient de noter qu'il reste encore du travail à faire pour améliorer les performances de prédiction et pour généraliser cette méthode à d'autres types d'agents.

Les progrès dans le domaine de la prédiction de mouvement peuvent contribuer de manière significative à la réalisation d'une conduite autonome plus sûre et plus performante. Il est crucial de poursuivre les recherches et les développements dans ce domaine pour garantir une adoption réussie et éthique de cette technologie dans l'avenir. En fin de compte, notre rapport souligne l'importance de la prédiction de mouvement pour la conduite autonome et montre la voie à suivre pour une avancée continue dans ce domaine.

5. Bibliographie et sources

- <https://www.kaggle.com/code/kool777/lyft-level5-eda-training-inference/notebook> (Consulté le 2 mars 2023).
- <https://www.kaggle.com/competitions/time-series-classification-adp> (Consulté le 2 mars 2023).
- <https://www.kaggle.com/competitions/lyft-motion-prediction-autonomous-vehicles/data> (Consulté le 2 mars 2023).
- <https://www.kaggle.com/code/corochann/lyft-deep-into-the-l5kit-library> (Consulté le 2 mars 2023).
-  The Truth About Self Driving Cars (Consulté le 22 février 2023).
-  Gradient Descent For Neural Network | Deep Learning Tutorial 12 (TensorFlow) (Consulté le 22 février 2023).
- IEEE TRANSACTIONS ON INTELLIGENT VEHICLES, VOL. 7, NO. 3, SEPTEMBER 2022 A Survey on Trajectory-Prediction Methods for Autonomous Driving , Yanjun Huang , Jiatong Du , Ziru Yang, Zewei Zhou , Lin Zhang , and Hong Chen , Senior Member, IEEE (Consulté le 18 février 2023).

voici quelque référence supplémentaire interne à cette source :

- [1] Y. Ma, Z. Wang, H. Yang, and L. Yang, “Artificial intelligence applications in the development of autonomous vehicles: A survey,” IEEE/CAA J. Automatica Sinica, vol. 7, no. 2, pp. 315–329, Mar. 2020.
- [2] F.-Y. Wang, “Metavehicles in the metaverse: Moving to a new phase for intelligent vehicles and smart mobility,” IEEE Trans. Intell. Veh., vol. 7, no. 1, pp. 1–5, Mar. 2022.
- [3] D. Cao et al., “Future directions of intelligent vehicles: Potentials, possibilities, and perspectives,” IEEE Trans. Intell. Veh., vol. 7, no. 1, pp. 6–10, Mar. 2022.
- [4] S. Lefèvre, D. Vasquez, and C. Laugier, “A survey on motion prediction and risk assessment for intelligent vehicles,” Robomech J., vol. 1, no. 1,

pp. 1–14, 2014.

669

[5] M. S. Shirazi and B. T. Morris, “Looking at intersections: A survey of intersection monitoring, behavior and safety analysis of recent studies,” *IEEE Trans. Intell. Transp. Syst.*, vol. 18, no. 1, pp. 4–24, Jan. 2017, doi: 10.1109/TITS.2016.2568920.

[6] S. Mozaffari, O. Y. Al-Jarrah, M. Dianati, P. A. Jennings, and A. Mouzakitis, “Deep learning-based vehicle behaviour prediction for autonomous driving applications: A review,” *IEEE Trans. Intell. Transp. Syst.*, vol. 23, no. 1, pp. 33–47, 2020.

[7] F. Leon and M. Gavrilescu, “A review of tracking and trajectory prediction methods for autonomous driving,” *Mathematics*, vol. 9, no. 6, pp. 660–696, 2021.

[8] J. Liu, X. Mao, Y. Fang, D. Zhu, and M. Q.-H. Meng, “A survey on deep-learning approaches for vehicle trajectory prediction in autonomous driving,” in *Proc. IEEE Int. Conf. Robot. Biomim.*, 2021, pp. 978–985, doi: 10.1109/ROBIO54168.2021.9739407.

[9] K. Santhoshk, P. Dograd, and P. Royp, “Anomaly detection in road traffic using visual surveillance: A survey,” *ACM Comput. Surv.*, vol. 53, no. 6, pp. 1–26, 2020.

[10] A. Ben Mabrouk and E. Zagrouba, “Abnormal behavior recognition for intelligent video surveillance systems: A review,” *Expert Syst. Appl.*, vol. 91, pp. 480–491, Jan. 2018.

[11] D. Ridel, E. Rehder, M. Lauer, C. Stiller, and D. Wolf, “A literature review on the prediction of pedestrian behavior in urban scenarios,” in

- Proc. 21st Int. Conf. Intell. Transp. Syst., 2018, pp. 3105–3112.
- [12] A. Rudenko, L. Palmieri, M. Herman, K. M. Kitani, D. M. Gavrila, and K. O. Arras, “Human motion trajectory prediction: A survey,” *Int. J. Robot. Res.*, vol. 39, no. 8, pp. 895–935, 2020.
- [13] W. Wang, R. Yu, Q. Huang, and U. Neumann, “SGPN: Similarity group proposal network for 3D point cloud instance segmentation,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 2569–2578.
- [14] S. Chen et al., “Vehicle-to-everything (V2X) services supported by LTE-based systems and 5G,” *IEEE Commun. Standards Mag.*, vol. 1, no. 2, pp. 70–76, Jul. 2017.
- [15] S. Ammoun and F. Nashashibi, “Real time trajectory prediction for collision risk estimation between vehicles,” in *Proc. IEEE 5th Int. Conf. Intell. Comput. Commun. Process.*, 2009, pp. 417–422.
- [16] A. Broadhurst, S. Baker, and T. Kanade, “Monte Carlo road safety reasoning,” in *Proc. IEEE Intell. Veh. Symp.*, 2005, pp. 319–324.
- [17] C. F. Lin and A. G. Ulsoy, “Vehicle dynamics and external disturbance estimation for vehicle path prediction,” *IEEE Trans. Control Syst. Technol.*, vol. 8, no. 3, pp. 508–518, May 2000.
- [18] R. Pepy, A. Lambert, and H. Mounier, “Reducing navigation errors by planning with realistic vehicle model,” in *Proc. Intell. Veh. Symp.*, 2006, pp. 300–307.
- [19] N. Kaempchen, B. Schiele, and K. Dietmayer, “Situation assessment of an autonomous emergency brake for arbitrary vehicle-to-vehicle collision scenarios,” *IEEE Trans. Intell. Transp. Syst.*, vol. 10, no. 4, pp. 678–687,

Dec. 2009.

[20] R. Schubert, E. Richter, and G. Wanielik, "Comparison and evaluation of advanced motion models for vehicle tracking," in Proc. 11th Int. Conf. Inf. Fusion, 2008, pp. 1–6.

[21] A. Polychronopoulos, M. Tsogas, A. J. Amditis, and L. Andreone, "Sensor fusion for predicting vehicles' path for collision avoidance systems," IEEE Trans. Intell. Transp. Syst., vol. 8, no. 3, pp. 549–562, Sep. 2007.

[22] P. Lytrivis, G. Thomaidis, and A. Amditis, "Cooperative path prediction in vehicular environments," in Proc. 11th Int. IEEE Conf. Intell. Transp. Syst., 2008, pp. 803–808.

[23] A. Barth and U. Franke, "Where will the oncoming vehicle be the next second?," in Proc. Intell. Veh. Symp., 2008, pp. 1068–1073.

[24] T. Batz, K. Watson, and J. Beyerer, "Recognition of dangerous situations within a cooperative group of vehicles," in Proc. Intell. Veh. Symp., 2009, pp. 907–912.

[25] M. Brannstrom, E. Coelingh, and J. Sjoberg, "Model-based threat assessment for avoiding arbitrary vehicle collisions," IEEE Trans. Intell. Transp. Syst., vol. 11, no. 3, pp. 658–669, Sep. 2010.

[26] R. Miller and Q. Huang, "An adaptive peer-to-peer collision warning system," in Proc. IEEE Veh. Technol. Conf., 2002, pp. 317–321.

[27] J. Hillenbrand, A. M. Spieker, and K. Kroschel, "A multilevel collision mitigation approach-its situation assessment, decision making, and performance tradeoffs," IEEE Trans. Intell. Transp. Syst., vol. 7, no. 4, pp. 528–540, Dec. 2006, doi: 10.1109/TITS.2006.883115.

[28] N. Kaempchen, K. Weiss, M. Schaefer, and K. C. J. Dietmayer, "IMM

object tracking for high dynamic driving maneuvers,” in *Intell. Veh.*

Symp., 2004, pp. 825–830.

Authorized licensed use limited to: Telecom ParisTech. Downloaded on February 17, 2023 at 09:10:52 UTC from IEEE Xplore. Restrictions apply.670

IEEE TRANSACTIONS ON INTELLIGENT VEHICLES, VOL. 7, NO. 3, SEPTEMBER 2022

[29] B. Jin, J. Bo, S. Tao, H. Liu, and G. Liu, “Switched kalman filter-interacting multiple model algorithm based on optimal autoregressive model for manoeuvring target tracking,” *IET Radar Sonar Navigation*, vol. 9, no. 2, pp. 199–209, 2015.

[30] H. Dyckmanns, R. Matthaei, M. Maurer, B. Lichte, and D. Stuker, “Object tracking in urban intersections based on active use of a priori knowledge: Active interacting multi model filter,” in *Proc. Intell. Veh. Symp.*, 2011, pp. 625–630.

[31] R. Zhang, L. Cao, S. Bao, and J. Tan, “A method for connected vehicle trajectory prediction and collision warning algorithm based on v2v communication,” *Int. J. Crashworthiness*, vol. 22, no. 1, pp. 15–25, 2017.

[32] V. Lefkopoulos, M. Menner, A. Domahidi, and M. N. Zeilinger, “Interaction-aware motion prediction for autonomous driving: A multiple model Kalman filtering scheme,” *IEEE Robot. Automat. Lett.*, vol. 6, no. 1, pp. 80–87, Oct. 2021.

[33] M. Althoff and A. Mergel, “Comparison of Markov chain abstraction and monte carlo simulation for the safety assessment of autonomous cars,” *IEEE Trans. Intell. Transp. Syst.*, vol. 12, no. 4, pp. 1237–1247, Dec. 2011.

[34] K. Okamoto, K. Berntorp, and S. Di Cairano, “Driver intention-based

- vehicle threat assessment using random forests and particle filtering,” IFAC-PapersOnLine, vol. 50, pp. 13 860–13 865, 2017.
- [35] Y. Wang, Z. Liu, Z. Zuo, Z. Li, L. Wang, and X. Luo, “Trajectory planning and safety assessment of autonomous vehicles based on motion prediction and model predictive control,” IEEE Trans. Veh. Technol., vol. 68, no. 9, pp. 8546–8556, Sep. 2019.
- [36] H. Song, D. Luan, W. Ding, M. Y. Wang, and Q. Chen, “Learning to predict vehicle trajectories with model-based planning,” in Conf. Robot Learn., 2022, pp. 1035–1045.
- [37] C. E. Rasmussen, “Gaussian processes in machine learning,” in Summer School Machine Learning, Berlin, Heidelberg, Germany: Springer, 2003, pp. 63–71.
- [38] J. Joseph, F. Doshi velez, and N. Roy, “A Bayesian nonparametric approach to modeling mobility patterns,” Autonom. Robot., vol. 31, no. 4, pp. 383–400, 2011.
- [39] J. Joseph, F. Doshi-Velez, A. S. Huang, and N. Roy, “A Bayesian nonparametric approach to modeling motion patterns,” Auton. Robots, vol. 31, no. 4, pp. 383–400, 2011.
- [40] Q. Tran and J. Firl, “Online maneuver recognition and multimodal trajectory prediction for intersection assistance using non-parametric regression,” in Proc. IEEE Intell. Veh. Symp., 2014, pp. 918–923.
- [41] C. Laugier et al., “Probabilistic analysis of dynamic scenes and collision risks assessment to improve driving safety,” IEEE Intell. Transp. Syst. Mag., vol. 3, no. 4, pp. 4–19, 2011, doi: 10.1109/MITS.2011.942779.
- [42] P. Trautman and A. Krause, “Unfreezing the robot: Navigation in dense,

- interacting crowds,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst., 2010, pp. 797–803.
- [43] Y. Guo et al., “Modeling multi-vehicle interaction scenarios using Gaussian random field,” in Proc. IEEE Intell. Transp. Syst. Conf., 2019, pp. 3974–3980.
- [44] D. A. V. Govea and T. Fraichard, “Motion prediction for moving objects: A statistical approach,” in Proc. IEEE Int. Conf. Robot. Automat., 2004, pp. 3931–3936.
- [45] C. Hermes, C. Wohler, K. Schenk, and F. Kummert, “Long-term vehicle motion prediction,” in Proc. Intell. Veh. Symp., 2010, pp. 652–657.
- [46] H. Mandalia and D. Salvucci, “Using support vector machines for lane-change detection,” in Proc. Hum. Factors Ergonom. Soc. Annu. Meeting, vol. 49, 2005, pp. 1965–1969.
- [47] P. Kumar, M. Perrollaz, S. Lefèvre, and C. Laugier, “Learning-based approach for online lane change intention prediction,” in Proc. IEEE Intell. Veh. Symp., 2013, pp. 797–802.
- [48] G. S. Aoude and J. P. How, “Using support vector machines and Bayesian filtering for classifying agent intentions at road intersections,” Sep. 2009.
- [49] G. S. Aoude, B. D. Luders, K. K. H. Lee, D. S. Levine, and J. P. How, “Threat assessment design for driver assistance system at intersections,” in Proc. 13th Int. IEEE Conf. Intell. Transp. Syst., 2010, pp. 1855–1862.
- [50] S. Gambs, M.-O. Killijian, and M. Nunez del Prado Cortez, “Next place prediction using mobility Markov chains,” in Proc. First Workshop Meas., Priv., Mobil., 2012, pp. 1–6.
- [51] Q. Deng and D. Söffker, “Improved driving behaviors prediction based

- on fuzzy logic-hidden Markov model (fl-hmm),” in Proc. IEEE Intell. Veh. Symp., 2018, pp. 2003–2008.
- [52] H. Berndt, J. Emmert, and K. Dietmayer, “Continuous driver intention recognition with hidden Markov models,” in Proc. Int. IEEE Conf. Intell. Transp. Syst., 2008, pp. 1189–1194.
- [53] S. Qiao, D. Shen, X. Wang, N. Han, and W. Zhu, “A self-adaptive parameter selection trajectory prediction approach via hidden Markov models,” *IEEE Trans. Intell. Transp. Syst.*, vol. 16, no. 1, pp. 284–296, Feb. 2015.
- [54] Y. Wang, C. Wang, W. Zhao, and C. Xu, “Decision-making and planning method for autonomous vehicles based on motivation and risk assessment,” *IEEE Trans. Veh. Technol.*, vol. 70, no. 1, pp. 107–120, Jan. 2021.
- [55] N. Deo, A. Ranges, and M. M. Trivedi, “How would surround vehicles move? A unified framework for maneuver classification and motion prediction,” *IEEE Trans. Intell. Veh.*, vol. 3, no. 2, pp. 129–140, Jun. 2018.
- [56] S. Zhang, Y. Zhi, R. He, and J. Li, “Research on traffic vehicle behavior prediction method based on game theory and hmm,” *IEEE Access*, vol. 8, pp. 30210–30222, Feb. 2020.
- [57] D. Koller and N. Friedman, *Probabilistic Graphical Models: Principles and Techniques*. Cambridge, MA, USA: MIT Press, 2009.
- [58] K. P. Murphy, “Dynamic Bayesian networks: Representation, inference and learning,” Ph.D. dissertation, Univ. California, Berkeley, 2002.
- [59] T. Gindele, S. Brechtel, and R. Dillmann, “Learning driver behavior models from traffic observations for decision making and planning,” *IEEE Intell. Transp. Syst. Mag.*, vol. 7, no. 1, pp. 69–79, 2015,

doi: 10.1109/MITS.2014.2357038.

[60] M. Schreier, V. Willert, and J. Adamy, "An integrated approach to maneuver-based trajectory prediction and criticality assessment in arbitrary road environments," *IEEE Trans. Intell. Transp. Syst.*, vol. 17, no. 10, pp. 2751–2766, Oct. 2016.

[61] M. Bahram, A. Lawitzky, J. Friedrichs, M. Aeberhard, and D. Wollherr, "A game-theoretic approach to replanning-aware interactive scene prediction and planning," *IEEE Trans. Veh. Technol.*, vol. 65, no. 6, pp. 3981–3992, Jun. 2015.

[62] G. He, X. Li, Y. Lv, B. Gao, and H. Chen, "Probabilistic intention prediction and trajectory generation based on dynamic Bayesian networks," in *Proc. Chin. Automat. Congr.*, 2019, pp. 2646–2651.

[63] J. Li, B. Dai, X. Li, X. Xu, and D. Liu, "A dynamic Bayesian network for vehicle maneuver prediction in highway driving scenarios: Framework and verification," *Electronics*, vol. 8, no. 1, pp. 40–58, Jan. 2019.

[64] Y. Li, X. Y. Lu, J. Wang, and K. Li, "Pedestrian trajectory prediction combining probabilistic reasoning and sequence learning," *IEEE Trans. Intell. Veh.*, vol. 5, no. 3, pp. 461–474, Sep. 2020.

[65] T. Heskes and O. Zoeter, "Expectation propagation for approximate inference in dynamic Bayesian networks," in *Proc. UAI-2002*, 12, Dec. 2012.

[66] G. Weidl, A. L. Madsen, D. Kasper, and G. Breuel, "Optimizing Bayesian networks for recognition of driving maneuvers to meet the automotive requirements," in *Proc. IEEE Int. Symp. Intell. Control*, 2014, pp. 1626–1631.

[67] A. Graves, "Generating sequences with recurrent neural networks," 2013,

arXiv:1308.0850.

[68] I. Sutskever, O. Vinyals, and Q. V. Le, "Sequence to sequence learning with neural networks," in *Adv. Neural Inf. Process. Syst.*, 2014, pp. 3104–3112.

[69] A. Zyner, S. Worrall, and E. Nebot, "A recurrent neural network solution for predicting driver intention at unsignalized intersections," *IEEE Robot. Automat. Lett.*, vol. 3, no. 3, pp. 1759–1764, Jul. 2018.

[70] A. Zyner, S. Worrall, J. Ward, and E. Nebot, "Long short term memory for driver intent prediction," in *Proc. Intell. Veh. Symp.*, 2017, pp. 1484–1489.

[71] D. J. Phillips, T. A. Wheeler, and M. J. Kochenderfer, "Generalizable intention prediction of human drivers at intersections," in *Proc. IEEE Intell. Veh. Symp.*, 2017, pp. 1665–1670.

[72] F. Altché and A. D. L. Fortelle, "An LSTM network for highway trajectory prediction," in *Proc. IEEE 20th Int. Conf. Intell. Transp. Syst.*, 2017, pp. 353–359.

[73] W. Ding and S. Shen, "Online vehicle trajectory prediction using policy anticipation network and optimization-based context reasoning," in *Proc. IEEE Int. Conf. Robot. Automat.*, 2019, pp. 9610–9616.

[74] A. Zyner, S. Worrall, and E. Nebot, "Naturalistic driver intention and path prediction using recurrent neural networks," *IEEE Trans. Intell. Transp. Syst.*, vol. 21, no. 4, pp. 1584–1594, Apr. 2019.

[75] S. H. Park, B. Kim, C. M. Kang, C. C. Chung, and J. W. Choi, "Sequence-to-sequence prediction of vehicle trajectory via lstm encoder-decoder architecture," in *Proc. IEEE Intell. Veh. Symp.*, 2018, pp. 1672–1678.

[76] Y. Xing, C. Lv, and D. Cao, "Personalized vehicle trajectory prediction

based on joint time-series modeling for connected vehicles,” IEEE Trans. Veh. Technol., vol. 69, no. 2, pp. 1341–1352, Feb. 2020.

[77] M.-F. Chang et al., “Argoverse: 3D tracking and forecasting with rich maps,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 8748–8757.

Authorized licensed use limited to: Telecom ParisTech. Downloaded on February 17, 2023 at 09:10:52 UTC from IEEE Xplore. Restrictions apply. HUANG et al.: SURVEY ON TRAJECTORY-PREDICTION METHODS FOR AUTONOMOUS DRIVING

[78] A. Kawasaki and A. Seki, “Multimodal trajectory predictions for urban environments using geometric relationships between a vehicle and lanes,” in Proc. IEEE Int. Conf. Robot. Automat., 2020, pp. 9203–9209.

[79] S. Dai, L. Li, and Z. Li, “Modeling vehicle interactions via modified lstm models for trajectory prediction,” IEEE Access, vol. 7, pp. 38287–38296, 2019.

[80] W. Ding, J. Chen, and S. Shen, “Predicting vehicle behaviors over an extended horizon using behavior interaction network,” in Proc. Int. Conf. Robot. Automat., 2019, pp. 8634–8640.

[81] L. Xin, P. Wang, C. Y. Chan, J. Chen, and B. Cheng, “Intention-aware long horizon trajectory prediction of surrounding vehicles using dual lstm networks,” in Proc. IEEE Int. Conf. Intell. Transp. Syst., 2018, pp. 1441–1446.

[82] N. Deo and M. M. Trivedi, “Multi-modal trajectory prediction of surrounding vehicles with maneuver based LSTMS,” in Proc. IEEE Intell. Veh. Symp., 2018, pp. 1179–1184.

[83] K. Min, D. Kim, J. Park, and K. Huh, “Rnn-based path prediction

- of obstacle vehicles with deep ensemble,” *IEEE Trans. Veh. Technol.*, vol. 68, no. 10, pp. 10252–10256, Oct. 2019.
- [84] C. Tang and R. R. Salakhutdinov, “Multiple futures prediction,” *Adv. Neural Inf. Process. Syst.*, vol. 32, pp. 15424–15434, Nov. 2019.
- [85] J. Mercat, T. Gilles, N. El Zoghby, G. Sandou, D. Beauvois, and G. P. Gil, “Multi-head attention for multi-modal joint vehicle motion forecasting,” in *Proc. IEEE Int. Conf. Robot. Automat.*, 2020, pp. 9638–9644.
- [86] X. Li, Y. Liu, K. Wang, and F.-Y. Wang, “A recurrent attention and interaction model for pedestrian trajectory prediction,” *IEEE/CAA J. Automatica Sinica*, vol. 7, no. 5, pp. 1361–1370, Sep. 2020.
- [87] T. Zhang, W. Song, M. Fu, Y. Yang, and M. Wang, “Vehicle motion prediction at intersections based on the turning intention and prior trajectories model,” *IEEE/CAA J. Automatica Sinica*, vol. 8, no. 10, pp. 1657–1666, Oct. 2021.
- [88] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “Imagenet classification with deep convolutional neural networks,” *Adv. Neural Inf. Process. Syst.*, vol. 25, pp. 1097–1105, 2012.
- [89] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2016, pp. 770–778.
- [90] J. Gehring, M. Auli, D. Grangier, D. Yarats, and Y. N. Dauphin, “Convolutional sequence to sequence learning,” in *Proc. Int. Conf. Mach. Learn.*, PMLR, 2017, pp. 1243–1252.
- [91] N. Nikhil and B. Tran Morris, “Convolutional neural network for trajectory prediction,” in *Proc. Eur. Conf. Comput. Vis. Workshops*,

2018.

- [92] T. Phan-Minh, E. C. Grigore, F. A. Boulton, O. Beijbom, and E. M. Wolff, "Covernet: Multimodal behavior prediction using trajectory sets," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 14074–14083.
- [93] H. Cui et al., "Deep kinematic models for kinematically feasible vehicle trajectory predictions," in *Proc. IEEE Int. Conf. Robot. Automat.*, 2020, pp. 10563–10569.
- [94] H. Cui et al., "Multimodal trajectory predictions for autonomous driving using deep convolutional networks," in *Proc. Int. Conf. Robot. Automat.*, 2019, pp. 2090–2096.
- [95] F.-C. Chou et al., "Predicting motion of vulnerable road users using high-definition maps and efficient convnets," in *Proc. IEEE Intell. Veh. Symp.*, 2020, pp. 1655–1662.
- [96] N. Djuric et al., "Uncertainty-aware short-term motion prediction of traffic actors for autonomous driving," in *Proc. IEEE/CVF Winter Conf. Appl. Comput. Vis.*, 2020, pp. 2095–2104.
- [97] J. Strohbeck et al., "Multiple trajectory prediction with deep temporal and spatial convolutional neural networks," in *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, 2020, pp. 1992–1998.
- [98] Y. Zhang, Y. Zou, J. Tang, and J. Liang, "A lane-changing prediction method based on temporal convolution network," 2020, arXiv:2011.01224.
- [99] F. Marchetti, F. Becattini, L. Seidenari, and A. D. Bimbo, "Mantra: Memory augmented networks for multiple trajectory prediction,"

in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2020, pp. 7143–7152.

[100] T. Gilles, S. Sabatini, D. Tsishkou, B. Stanciulescu, and F. Moutarde, “Home: Heatmap output for future motion estimation,” in Proc. IEEE Int. Intell. Transp. Syst. Conf., 2021, pp. 500–507.

[101] M. Ye, T. Cao, and Q. Chen, “Tpcn: Temporal point cloud networks for motion forecasting,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2021, pp. 11318–11327.

671

[102] N. Deo and M. M. Trivedi, “Convolutional social pooling for vehicle trajectory prediction,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. Workshops, 2018, pp. 1468–1476.

[103] A. Alahi, K. Goel, V. Ramanathan, A. Robicquet, and S. Savarese, “Social lstm: Human trajectory prediction in crowded spaces,” in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2016, pp. 961–971.

[104] R. Chandra, U. Bhattacharya, A. Bera, and D. Manocha, “Trophic: Trajectory prediction in dense and heterogeneous traffic using weighted interactions,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 8483–8492.

[105] G. Xie, A. Shangguan, R. Fei, W. Ji, and X. Hei, “Motion trajectory prediction based on a CNN-LSTM sequential model,” *Science China. Inf. Sci.*, vol. 63, no. 11, pp. 1–21, Nov. 2020.

[106] S. Casas, C. Gulino, S. Suo, and R. Urtasun, “The importance of prior knowledge in precise multimodal prediction,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst., 2020, pp. 2295–2302.

- [107] N. Lee, W. Choi, P. Vernaza, C. B. Choy, P. H. Torr, and M. Chandraker, "Desire: Distant future prediction in dynamic scenes with interacting agents," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017, pp. 336–345.
- [108] J. Hong, B. Sapp, and J. Philbin, "Rules of the road: Predicting driving behavior with a convolutional model of semantic interactions," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 8454–8462.
- [109] Y. Chai, B. Sapp, M. Bansal, and D. Anguelov, "Multipath: Multiple probabilistic anchor trajectory hypotheses for behavior prediction," 2019, arXiv:1910.05449.
- [110] D. Hu, "An introductory survey on attention mechanisms in NLP problems," in Proc. SAI Intell. Syst. Conf., Springer, 2019, pp. 432–448.
- [111] V. Mnih et al., "Recurrent models of visual attention," in Proc. Adv. Neural Inf. Process. Syst., 2014, pp. 2204–2212.
- [112] D. Bahdanau, K. Cho, and Y. Bengio, "Neural machine translation by jointly learning to align and translate," in Proc. 3rd Int. Conf. Learn. Represent., 2015, arXiv:1409.0473.
- [113] D. Varshneya and G. Srinivasaraghavan, "Human trajectory prediction using spatially aware deep attention models," 2017, arXiv:1705.09436.
- [114] S. Haddad, M. Wu, H. Wei, and S. K. Lam, "Situation-aware pedestrian trajectory prediction with spatio-temporal attention model," 2019, arXiv:1902.05437.
- [115] T. Fernando, S. Denman, S. Sridharan, and C. Fookes, "Soft hardwired attention: An LSTM framework for human trajectory prediction and abnormal event detection," Neural Netw., vol. 108, pp. 466–478,

Dec. 2018.

[116] H. Kim, D. Kim, G. Kim, J. Cho, and K. Huh, “Multi-head attention based probabilistic vehicle trajectory prediction,” in Proc. IEEE Intell. Veh. Symp., 2020, pp. 1720–1725.

[117] K. Messaoud, I. Yahiaoui, A. Verroust-Blondet, and F. Nashashibi, “Attention based vehicle trajectory prediction,” IEEE Trans. Intell. Veh., vol. 6, no. 1, pp. 175–185, May 2020.

[118] K. Messaoud, N. Deo, M. M. Trivedi, and F. Nashashibi, “Trajectory prediction for autonomous driving based on multi-head attention with joint agent-map representation,” in Proc. IEEE Intell. Veh. Symp., 2021, pp. 165–170.

[119] A. Vaswani et al., “Attention is all you need,” in Proc. Adv. Neural Inf. Process. Syst., 2017, pp. 5998–6008.

[120] F. Giuliari, I. Hasan, M. Cristani, and F. Galasso, “Transformer networks for trajectory forecasting,” in Proc. 25th Int. Conf. Pattern Recognit., 2021, pp. 10335–10342.

[121] Z. Huang, X. Mo, and C. Lv, “Multi-modal motion prediction with transformer-based neural network for autonomous driving,” 2021, arXiv:2109.06446.

[122] L. L. Li et al., “End-to-end contextual perception and prediction with interaction transformer,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst., 2020, pp. 5784–5791.

[123] J. Ngiam et al., “Scene transformer: A unified multi-task model for behavior prediction and planning,” in Proc. Int. Conf. Learn. Representations, 2021.

[124] Y. Liu, J. Zhang, L. Fang, Q. Jiang, and B. Zhou, "Multimodal motion prediction with stacked transformers," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2021, pp. 7577–7586.

[125] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, "A comprehensive survey on graph neural networks," IEEE Trans. Neural Netw. Learn. Syst., vol. 32, no. 1, pp. 4–24, Jan. 2020.

[126] F. Diehl, T. Brunner, M. T. Le, and A. Knoll, "Graph neural networks for modelling traffic participant interaction," in Proc. IEEE Intell. Veh. Symp., 2019, pp. 695–701.

Authorized licensed use limited to: Telecom ParisTech. Downloaded on February 17, 2023 at 09:10:52 UTC from IEEE Xplore. Restrictions apply.

IEEE TRANSACTIONS ON INTELLIGENT VEHICLES, VOL. 7, NO. 3, SEPTEMBER 2022

[127] X. Li, X. Ying, and M. C. Chuah, "Grip: Graph-based interaction-aware trajectory prediction," in Proc. IEEE Intell. Transp. Syst. Conf., 2019, pp. 3960–3966.

[128] X. Li, X. Ying, and M. C. Chuah, "Grip++: Enhanced graph-based interaction-aware trajectory prediction for autonomous driving," 2019, arXiv:1907.07792.

[129] X. Huang, P. Wang, X. Cheng, D. Zhou, Q. Geng, and R. Yang, "The apolloscape open dataset for autonomous driving and its application," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. Workshops, 2018, pp. 2702–2719.

[130] H. Jeon, J. Choi, and D. Kum, "SCALE-Net: Scalable vehicle trajectory prediction network under random number of interacting vehicles via edge-enhanced graph convolutional neural network," in Proc. IEEE/RSJ

- Int. Conf. Intell. Robots Syst., 2020, pp. 2095–2102.
- [131] L. Gong and Q. Cheng, “Exploiting edge features in graph neural networks,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2018, pp. 9211–9219.
- [132] A. Mohamed, K. Qian, M. Elhoseiny, and C. Claudel, “Social-STGCNN: A social spatio-temporal graph convolutional neural network for human trajectory prediction,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2020, pp. 14424–14432.
- [133] R. Chandra et al., “Forecasting trajectory and behavior of road-agents using spectral clustering in graph-LSTMS,” IEEE Robot. Automat. Lett., vol. 5, no. 3, pp. 4882–4890, Jun. 2020.
- [134] B. M. Waxman, “Routing of multipoint connections,” IEEE J. Sel. Areas Commun, vol. 6, no. 9, pp. 1617–1622, Dec. 1988.
- [135] Z. Zhao, H. Fang, Z. Jin, and Q. Qiu, “Gisnet: Graph-based information sharing network for vehicle trajectory prediction,” in Proc. Int. Joint Conf. Neural Netw., 2020, pp. 1–7.
- [136] J. Ziegler et al., “Making bertha drive-an autonomous journey on a historic route,” IEEE Intell. Transp. Syst. Mag., vol. 6, no. 2, pp. 8–20, 2014, doi: 10.1109/MITS.2014.2306552.
- [137] J. Gao et al., “Vectornet: Encoding hd maps and agent dynamics from vectorized representation,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2020, pp. 11525–11533.
- [138] M. Liang et al., “Learning lane graph representations for motion forecasting,” in Proc. Eur. Conf. Comput. Vis. Springer, 2020, pp. 541–556.

- [139] H. Zhao et al., “Tnt: Target-driven trajectory prediction,” in Proc. Conf. Robot Learn., 2020, pp. 895–904.
- [140] J. Gu, C. Sun, and H. Zhao, “Densetnt: End-to-end trajectory prediction from dense goal sets,” in Proc. IEEE/CVF Int. Conf. Comput. Vis., 2021, pp. 15303–15312.
- [141] W. Zeng, M. Liang, R. Liao, and R. Urtasun, “Lanercnn: Distributed representations for graph-centric motion forecasting,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst., 2021, pp. 532–539.
- [142] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Lio, and Y. Bengio, “Graph attention networks,” in Proc. 6th Int. Conf. Learn. Representations, 2018.
- [143] Y. Huang, H. Bi, Z. Li, T. Mao, and Z. Wang, “Stgat: Modeling spatial-temporal interactions for human trajectory prediction,” in Proc. Int. Conf. Comput. Vis., 2019, pp. 6271–6280.
- [144] L. Zhang, Q. She, and P. Guo, “Stochastic trajectory prediction with social graph network,” 2019, arXiv:1907.10233.
- [145] T. Salzmann, B. Ivanovic, P. Chakravarty, and M. Pavone, “Trajectron: Dynamically-feasible trajectory forecasting with heterogeneous data,” in Proc. Eur. Conf. Comput. Vis. Springer, 2020, pp. 683–700.
- [146] I. Goodfellow et al., “Generative adversarial nets,” in Proc. Adv. Neural Inf. Process. Sys., vol. 27, 2014.
- [147] A. Gupta, J. Johnson, L. Fei-Fei, S. Savarese, and A. Alahi, “Social gan: Socially acceptable trajectories with generative adversarial networks,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2018,

pp. 2255–2264.

- [148] B. Yang, G. Yan, P. Wang, C.-Y. Chan, X. Liu, and Y. Chen, “Tppo: A novel trajectory predictor with pseudo oracle,” 2020.
- [149] J. Li, H. Ma, and M. Tomizuka, “Conditional generative neural system for probabilistic trajectory prediction,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst., 2019, pp. 6150–6156.
- [150] A. Sadeghian, V. Kosaraju, A. Sadeghian, N. Hirose, H. Rezatofighi, and S. Savarese, “Sophie: An attentive gan for predicting paths compliant to social and physical constraints,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 1349–1358.
- [151] C. Hegde, S. Dash, and P. Agarwal, “Vehicle trajectory prediction using gan,” in Proc. Fourth Int. Conf. (IoT Social, Mobile, Analytics Cloud), 2020, pp. 502–507.
- [152] T. Zhao et al., “Multi-agent tensor fusion for contextual trajectory prediction,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2019, pp. 12126–12134.
- [153] Y. Wang, S. Zhao, R. Zhang, X. Cheng, and L. Yang, “Multi-vehicle collaborative learning for trajectory prediction with spatio-temporal tensor fusion,” *IEEE Trans. Intell. Transp. Syst.*, vol. 23, no. 1, pp. 236–248, Jan. 2022.
- [154] D. P. Kingma and M. Welling, “Auto-encoding variational bayes,” in Proc. 2nd Int. Conf. Learn. Represent., 2014, arXiv:1312.6114.
- [155] K. Sohn, H. Lee, and X. Yan, “Learning structured output representation using deep conditional generative models,” *Adv. Neural Inf. Process. Syst.*, vol. 28, pp. 3483–3491, Jan. 2015.

- [156] N. Rhinehart, K. M. Kitani, and P. Vernaza, "R2p2: A reparameterized pushforward policy for diverse, precise generative path forecasting," in *Proc. Eur. Conf. Comput. Vis.*, 2018, pp. 772–788.
- [157] S. Casas, C. Gulino, S. Suo, K. Luo, R. Liao, and R. Urtasun, "Implicit latent variable model for scene-consistent motion forecasting," in *Proc. Eur. Conf. Comput. Vis.*. Springer, 2020, pp. 624–641.
- [158] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, "Pointnet++: Deep hierarchical feature learning on point sets in a metric space," *Adv. Neural Inf. Process. Syst.*, vol. 30, 2017.
- [159] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "Pointnet: Deep learning on point sets for 3 d classification and segmentation," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2017, pp. 652–660.
- [160] V. Mnih et al., "Human-level control through deep reinforcement learning," *Nature*, vol. 518, no. 7540, pp. 529–533, Feb. 2015.
- [161] D. Silver et al., "Mastering the game of go with deep neural networks and tree search," *Nature*, vol. 529, no. 7587, pp. 484–489, Jan. 2016.
- [162] B. Hjaltason, "Predicting vehicle trajectories with inverse reinforcement learning," 2019.
- [163] B. R. Kiran et al., "Deep reinforcement learning for autonomous driving: A survey," *IEEE Trans. Intell. Transp. Syst.*, vol. 23, no. 6, pp. 4909–4926, Jun. 2022.
- [164] T. Fernando, S. Denman, S. Sridharan, and C. Fookes, "Deep inverse reinforcement learning for behavior prediction in autonomous driving: Accurate forecasts of vehicle motion," *IEEE Signal Process. Mag.*, vol. 38, no. 1, pp. 87–96, Jan. 2020.

- [165] R. Bellman, "A Markovian decision process," *J. Math. Mechanics*, vol. 6, no. 5, pp. 679–684, 1957.
- [166] P. Wang, C.-Y. Chan, and A. de La Fortelle, "A reinforcement learning based approach for automated lane change maneuvers," in *Proc. IEEE Intell. Veh. Symp.*, 2018, pp. 1379–1384.
- [167] Y. Guan, S. E. Li, J. Duan, W. Wang, and B. Cheng, "Markov probabilistic decision making of self-driving cars in highway with random traffic flow: A simulation study," *J. Intell. Connected Veh.*, vol. 1, no. 2, pp. 77–84, 2018, doi: 10.1108/JICV-01-2018-0003.
- [168] N. D. Ratliff, J. A. Bagnell, and M. A. Zinkevich, "Maximum margin planning," in *Proc. 23rd Int. Conf. Mach. Learn.*, 2006, pp. 729–736.
- [169] E. Klein, M. Geist, B. Piot, and O. Pietquin, "Inverse reinforcement learning through structured classification," in *Proc. Neural Inf. Process. Syst.*, 2012, pp. 1–9.
- [170] D. Silver, J. A. Bagnell, and A. Stentz, "Learning autonomous driving styles and maneuvers from expert demonstration," in *Experimental Robotics. Heidelberg Germany: Springer*, 2013, pp. 371–386.
- [171] B. D. Ziebart et al., "Maximum entropy inverse reinforcement learning," *Aaai*, vol. 8, pp. 1433–1438, 2008.
- [172] M. Herman, V. Fischer, T. Gindele, and W. Burgard, "Inverse reinforcement learning of behavioral models for online-adapting navigation strategies," in *Proc. IEEE Int. Conf. Robot. Automat.*, 2015, pp. 3215–3222.
- [173] S. Sharifzadeh, I. Chiotellis, R. Triebel, and D. Cremers, "Learning to drive using inverse reinforcement learning and deep q-networks," 2016, arXiv:1612.03653.

[174] L. Sun, W. Zhan, and M. Tomizuka, "Probabilistic prediction of interactive driving behavior via hierarchical inverse reinforcement learning," in Proc. 21st Int. Conf. Intell. Transp. Syst., 2018, pp. 2111–2117.

[175] D. S. González, O. Erkent, V. Romero-Cano, J. Dibangoye, and C. Laugier, "Modeling driver behavior from demonstrations in dynamic environments using spatiotemporal lattices," in Proc. IEEE Int. Conf. Robot. Automat., 2018, pp. 3384–3390.

[176] D. Xu et al., "Learning from naturalistic driving data for human-like autonomous highway driving," IEEE Trans. Intell. Transp. Syst., vol. 22, no. 12, pp. 7341–7354, Dec. 2020.

[177] Z. Wu, L. Sun, W. Zhan, C. Yang, and M. Tomizuka, "Efficient sampling-based maximum entropy inverse reinforcement learning with application to autonomous driving," IEEE Robot. Automat. Lett., vol. 5, no. 4, pp. 5355–5362, Oct. 2020.

Authorized licensed use limited to: Telecom ParisTech. Downloaded on February 17, 2023 at 09:10:52 UTC from IEEE Xplore. Restrictions apply. HUANG et al.: SURVEY ON TRAJECTORY-PREDICTION METHODS FOR AUTONOMOUS DRIVING

[178] N. Deo and M. M. Trivedi, "Trajectory forecasts in unknown environments conditioned on grid-based plans," 2020, arXiv:2001.00735.

[179] L. Xin et al., "Accelerated inverse reinforcement learning with randomly pre-sampled policies for autonomous driving reward design," in Proc. IEEE Intell. Transp. Syst. Conf., 2019, pp. 2757–2764.

[180] Y. Xu, T. Zhao, C. Baker, Y. Zhao, and Y. N. Wu, "Learning trajectory prediction with continuous inverse optimal control via langevin sampling of energy-based models," 2019, arXiv:1904.05453.

- [181] Z. Huang, J. Wu, and C. Lv, "Driving behavior modeling using naturalistic human driving data with inverse reinforcement learning," *IEEE Trans. Intell. Transp. Syst.*, vol. 23, no. 8, pp. 10239–10251, Aug. 2022.
- [182] A. Kuefler, J. Morton, T. Wheeler, and M. Kochenderfer, "Imitating driver behavior with generative adversarial networks," in *Proc. IEEE Intell. Veh. Symp.*, 2017, pp. 204–211.
- [183] Y. Li, J. Song, and S. Ermon, "Infogail: Interpretable imitation learning from visual demonstrations," in *Proc. 31st Int. Conf. Neural Inf. Process. Syst.*, 2017, pp. 3815–3825.
- [184] R. Bhattacharyya et al., "Modeling human driving behavior through generative adversarial imitation learning," 2020, arXiv:2006.06412.
- [185] S. Choi, J. Kim, and H. Yeo, "Trajgail: Generating urban vehicle trajectories using generative adversarial imitation learning," *Transp. Res. Part C: Emerg. Technol.*, vol. 128, Jul. 2021, Art. no. 103091.
- [186] C. You, J. Lu, D. Filev, and P. Tsiotras, "Advanced planning for autonomous vehicles using reinforcement learning and deep inverse reinforcement learning," *Robot. Auton. Syst.*, vol. 114, pp. 1–18, Apr. 2019.
- [187] M. Wulfmeier, D. Rao, D. Z. Wang, P. Ondruska, and I. Posner, "Large-scale cost function learning for path planning using deep inverse reinforcement learning," *Int. J. Robot. Res.*, vol. 36, no. 10, pp. 1073–1087, Sep. 2017.
- [188] Q. Zou, H. Li, and R. Zhang, "Inverse reinforcement learning via neural network in driver behavior modeling," in *Proc. IEEE Intell. Veh. Symp.*, 2018, pp. 1245–1250.
- [189] Z. Zhu, N. Li, R. Sun, D. Xu, and H. Zhao, "Off-road autonomous

vehicles traversability analysis and trajectory planning based on deep inverse reinforcement learning,” in Proc. IEEE Intell. Veh. Symp., 2020, pp. 971–977.

[190] C. Jung and D. H. Shim, “Incorporating multi-context into the traversability map for urban autonomous driving using deep inverse reinforcement learning,” IEEE Robot. Automat. Lett., vol. 6, no. 2, pp. 1662–1669, Apr. 2021.

[191] J. Ho and S. Ermon, “Generative adversarial imitation learning,” Adv. Neural Inf. Process. Syst., vol. 29, pp. 4565–4573, 2016.

[192] M. Wulfmeier, P. Ondruska, and I. Posner, “Maximum entropy deep inverse reinforcement learning,” 2015, arXiv:1507.04888.

[193] M. Wulfmeier, D. Z. Wang, and I. Posner, “Watch this: Scalable cost-function learning for path planning in urban environments,” in Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst., 2016, pp. 2089–2095.

[194] “Traffic analysis tools,” Accessed: Jan. 6, 2021. [Online]. Available: <https://ops.fhwa.dot.gov/trafficanalysistools/index.htm>

[195] H. Caesar et al., “nusenes: A multimodal dataset for autonomous driving,” in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2020, pp. 11621–11631.

[196] S. Ettinger et al., “Large scale interactive motion forecasting for autonomous driving: The waymo open motion dataset,” in Proc. IEEE/CVF Int. Conf. Comput. Vis., 2021, pp. 9710–9719.

[197] J. Houston et al., “One thousand and one hours: Self-driving motion prediction dataset,” in Proc. Conf. Robot Learn., vol. 155, 2020, pp. 409–418.

- [198] B. Wilson et al., “Argoverse 2: Next generation datasets for self-driving perception and forecasting,” in Proc. Neural Inf. Process. Syst. Track Datasets Benchmarks, 2021.
- [199] W. Zhan et al., “Interaction dataset: An international, adversarial and cooperative motion dataset in interactive driving scenarios with semantic maps,” 2019, arXiv:1910.03088.
- [200] R. Krajewski, J. Bock, L. Kloeker, and L. Eckstein, “The highd dataset: A drone dataset of naturalistic vehicle trajectories on German highways for validation of highly automated driving systems,” in Proc. 21st Int. Conf. Intell. Transp. Syst., 2018, pp. 2118–2125.
- [201] A. Geiger, P. Lenz, C. Stiller, and R. Urtasun, “Vision meets robotics: The kitti dataset,” Int. J. Robot. Res., vol. 32, no. 11, pp. 1231–1237, Sep. 2013.
- [202] K. Saleh, M. Hossny, and S. Nahavandi, “Long-term recurrent predictive model for intent prediction of pedestrians via inverse reinforcement learning,” in Proc. Digit. Image Comput.: Techn. Appl., 2018, pp. 1–8. 673
- [203] T. Fernando, S. Denman, S. Sridharan, and C. Fookes, “Neighbourhood context embeddings in deep inverse reinforcement learning for predicting pedestrian motion over long time horizons,” in Proc. IEEE/CVF Int. Conf. Comput. Vis. Workshops, 2019.
- [204] M. Bahram, C. Hubmann, A. Lawitzky, M. Aeberhard, and D. Wollherr, “A combined model-and learning-based framework for interaction-aware maneuver prediction,” IEEE Trans. Intell. Transp. Syst., vol. 17, no. 6, pp. 1538–1550, Jun. 2016.

- [205] S. Wang, P. Zhao, B. Yu, W. Huang, and H. Liang, "Vehicle trajectory prediction by knowledge-driven lstm network in urban environments," J. Adv. Transp., vol. 2020, 2020.
- [206] "Inter-tnt (jointly vectornet-tnt-interaction) evaluator," Accessed: Mar. 26, 2022. [Online]. Available: https://github.com/ApolloAuto/apollo/blob/master/docs/technical_documents/jointly_prediction_planning_evaluator.md